กลยุทธ์ AI Dataset และการทำ Fine-tuning บน AWS สำหรับ LegalGuard AI

1. บทนำและแนวคิดหลัก

เพื่อให้ **LegalGuard AI** มีความแม่นยำสูงสุดในบริบทกฎหมายไทย ทั้งในส่วนของ **ศาลยุติธรรม** และ **ศาลปกครอง** เราจะใช้กลยุทธ์การบูรณาการระหว่าง **AWS Foundation Models/Datasets** ร่วมกับ **Custom Legal Dataset** ของเราเอง เพื่อทำ **Fine-tuning** และ **RAG (Retrieval-Augmented Generation)** ให้ตอบโจทย์ผู้ใช้งานทั้งประชาชนและเจ้าหน้าที่รัฐ [1] [2] [3].

2. แหล่งข้อมูล AI Dataset (Integrated Dataset Strategy)

เราจะแบ่ง Dataset ออกเป็น 2 ส่วนหลัก เพื่อนำมาประยุกต์ใช้ร่วมกัน:

2.1 ข้อมูลมาตรฐานจาก AWS (AWS Foundation & Open Datasets)

- **AWS Open Data Sponsorship Program:** เข้าถึง Dataset สาธารณะขนาดใหญ่ที่ AWS สนับสนุน เพื่อใช้เป็นฐานความรู้ทั่วไปและโครงสร้างภาษา [3].
- **Amazon Bedrock Foundation Models:** ใช้ความรู้พื้นฐานจากโมเดลระดับโลก (เช่น Claude 3.5, Amazon Nova) ที่ผ่านการ Pre-train ด้วยข้อมูลมหาศาล [3].
- **AWS Data Exchange:** สำหรับการเข้าถึงข้อมูลเฉพาะทางจาก Third-party (หากจำเป็น) เพื่อเสริมความแข็งแกร่งด้านข้อมูลเศรษฐกิจหรือสังคมที่เกี่ยวข้องกับคดีปกครอง [3].

2.2 ข้อมูลเฉพาะทางกฎหมายไทย (Custom Legal Dataset)

เราจะนำข้อมูลจาก Google Sheets (ชุด A และ B) และเอกสารศาลปกครองมาจัดเตรียมเป็น Dataset สำหรับ Fine-tuning [1] [2]:

ประเภทข้อมูล	รายละเอียด Dataset สำหรับ Fine-tuning	รูปแบบข้อมูล (Format)
คดีศาลยุติธรรม	คำพิพากษาศาลฎีกา, แบบฟอร์มคำฟ้องแพ่ง/อาญา, คู่มือ e-Filing [2].	JSONL (Prompt-Completion)
คดีศาลปกครอง	คำพิพากษาศาลปกครองสูงสุด, พ.ร.บ. จัดตั้งศาลปกครองฯ, แบบคำฟ้อง ปค. 1 [1] [2].	JSONL (Instruction-based)
ภาษาไทยกฎหมาย	พจนานุกรมกฎหมายไทย, คำศัพท์เฉพาะทางในศาล, รูปแบบการเขียนหนังสือราชการ [1].	Text/CSV (Domain Adaptation)

3. กระบวนการ Fine-tuning และการพัฒนาโมเดลบน AWS

เราจะใช้เครื่องมือจาก AWS ในการจัดการวงจรชีวิตของโมเดล AI (ML Lifecycle) ดังนี้:

3.1 การเตรียมข้อมูล (Data Preparation)

- **Amazon SageMaker Ground Truth:** ใช้สำหรับ Label ข้อมูลที่ซับซ้อน เช่น การระบุมาตรากฎหมายในคำพิพากษา หรือการคัดกรองข้อมูล PII (Personally Identifiable Information) [3].
- **AWS Glue DataBrew:** ใช้ในการทำ Data Cleaning และจัดการรูปแบบข้อมูลให้เป็นมาตรฐานเดียวกันก่อนนำไป Fine-tune [3].

3.2 การทำ Fine-tuning (Model Customization)

- **Amazon Bedrock Fine-tuning:** สำหรับการปรับแต่ง Foundation Models (เช่น Claude) ด้วยข้อมูลกฎหมายไทย เพื่อให้โมเดลเข้าใจสำนวนภาษาและขั้นตอนของศาลไทยได้ดียิ่งขึ้น [3].
- **Amazon SageMaker Training Jobs:** ใช้สำหรับการฝึกฝนโมเดลเฉพาะทาง (เช่น WangchanX-Legal) โดยใช้ GPU Instances (P4/P5) หรือ AWS Trainium เพื่อประสิทธิภาพสูงสุดและประหยัดค่าใช้จ่าย [3].

3.3 การประยุกต์ใช้ในโมดูลต่างๆ

โมดูลผู้ใช้	เทคนิค AI ที่ใช้	ผลลัพธ์ที่คาดหวัง
ประชาชน	Fine-tuned RAG (Bedrock + Knowledge Bases)	ตอบคำถามกฎหมายด้วยภาษาที่เข้าใจง่าย แต่มีความถูกต้องตามหลักการของทั้งสองศาล [1] [2].
เจ้าหน้าที่รัฐ	Instruction Fine-tuning (SageMaker)	ช่วยร่างเอกสารราชการและสรุปประเด็นข้อกฎหมายในคำพิพากษาได้อย่างแม่นยำและรวดเร็ว [1] [2].

4. สถาปัตยกรรมข้อมูลและความปลอดภัย (Data Governance)

- **Amazon S3 & AWS Lake Formation:** จัดเก็บ Dataset แยกตามระดับความลับและประเภทศาล พร้อมกำหนดสิทธิ์การเข้าถึงอย่างเข้มงวด [3].
- **Amazon Bedrock Guardrails:** กำหนดนโยบายเพื่อป้องกันไม่ให้ AI ให้คำแนะนำทางกฎหมายที่ผิดพลาด หรือเปิดเผยข้อมูลส่วนบุคคล [3].

- **AWS CloudTrail:** บันทึกทุกกิจกรรมการเข้าถึง Dataset เพื่อการตรวจสอบ (Audit) ตามมาตรฐานหน่วยงานรัฐ [3].

5. สรุปรายการเอกสารที่ต้องนำมาทำ Dataset

เพื่อให้การ Fine-tuning ประสบความสำเร็จ เราต้องนำไฟล์เอกสารต่อไปนี้มาประมวลผล:

1. **ไฟล์ PDF ศาลปกครอง:** "บรรยายพิเศษ-การนำเสนอภาพรวมกระบวนการทำงานของศาลปกครอง..." เพื่อสกัดขั้นตอนและวิสัยทัศน์ [1].
2. **รายการจาก Google Sheets (ชุด A & B):** แบบฟอร์ม, คู่มือ, กฎหมาย และคำพิพากษาทั้งหมด เพื่อสร้างชุดข้อมูล Instruction-Response [2].
3. **ไฟล์ XML/JSON Schema:** จากระบบ e-Filing เพื่อให้ AI เข้าใจโครงสร้างข้อมูลทางเทคนิคของศาล [2].

References

[1] บรรยายพิเศษ - การนำเสนอภาพรวมกระบวนการทำงานของศาลปกครอง ดร.ระดาภัทร จงธรรมคุณ ที่ปรึกษาฯ. (2569). [ไฟล์ PDF ที่แนบมา]

[2] Google Sheets: สารบัญ - ข้อมูลเกี่ยวกับกระบวนการยุติธรรม เพื่อประกอบการแข่งขัน. (n.d.).

[3] บรรยายพิเศษ - AI Infrastructure & AI Innovation คุณศาศวัต นธการกิจกุล DATA & AI Lead, Amazon Web Services (ประเทศไทย). (2569).